

Auditoria e comparação dos benchmarks

Touring Polygons

Relatório reproduzível a partir dos dois CSVs finais

2026-09-20

Abstract

Este relatório verifica a integridade dos resultados finais e compara o solver de ordem livre com o solver alemão de ordem fixa. A análise usa somente os dois CSVs canônicos, sem recuperar métricas de arquivos intermediários. O resultado principal é uma vantagem consistente do solver de ordem livre: ele certificou todas as 558 instâncias, enquanto o solver alemão certificou 498 das 557 instâncias comparáveis dentro dos limites usados.

Resumo executivo

Solver	Instâncias	Exatas	Taxa exata	Mediana exata (s)	Média exata (s)
ordem livre	558	558	100.0%	0.08	80.59
solver alemão	557	498	89.4%	0.31	98.84

No conjunto comum de 557 instâncias exatas para o solver alemão, o speedup definido como $T_{\text{German}}/T_{\text{free}}$ teve mediana 4.47x e média 1 178.15x. Valores acima de 1 favorecem o solver de ordem livre. A comparação deve ser lida como benchmark de engenharia: os solvers têm espaços de busca e métricas internas diferentes.

1 Verificação dos dados

Table 1: Checks automáticos executados sobre os dois arquivos finais.

Verificação	Critério	Resultado
Linhas livres	558 linhas e 558 índices únicos	PASS
Linhas alemãs	557 linhas e 557 índices únicos	PASS
Interseção	557 instâncias comuns, sem duplicações	PASS
Exatidão livre	exact coincide com termination=optimal	PASS
Exatidão alemã	exhausted e nenhum limite ativo	PASS
Branching final	nenhuma linha alemã com branch_limited=true	PASS
Valores não finitos	nenhum token NaN/Inf detectado	PASS

O arquivo alemão exclui a instância 554, que apresentou uma falha determinística **SIGBUS** no binário alemão. Os hashes SHA-256 dos arquivos analisados estão registrados em **validation.json**, junto com as contagens completas usadas nesta auditoria.

2 Instâncias resolvidas ao longo do tempo




Figure 1: Número acumulado de instâncias certificadas em função do tempo. A curva alemã termina em 498 porque 59 instâncias atingiram o limite de tempo.

3 Distribuição de tempos e speedup




Figure 2: Distribuição dos tempos somente entre instâncias certificadas. O eixo vertical é logarítmico para preservar os casos muito rápidos e os casos difíceis.




Figure 3: Distribuição do speedup nos 498 casos exatos em ambos os solvers. A linha em zero representa desempenho igual; barras à direita favorecem a ordem livre.

Table 2: Resumo do speedup nos casos exatos comuns.

Métrica	Valor
Casos comuns exatos	498
Mediana	4.47x
Média aritmética	1 178.15x
Percentil 10 / 90	0.01x / 352.29x
Casos em que ordem livre foi mais rápida	59.2%

4 Relação caso a caso




Figure 4: Comparação caso a caso em escala log-log. Pontos acima da diagonal indicam que o solver de ordem livre foi mais rápido.

5 Métricas exclusivas de cada abordagem

As métricas abaixo não são equivalentes entre si; elas descrevem mecanismos internos distintos e servem principalmente para diagnosticar por que os custos de busca diferem.

Table 3: Métricas internas da ordem livre.

Métrica	Coluna	Mediana	P90
best updates	best_updates	3.00	10.00
order space (log2)	order_space_log2	107.71	266.23
insertion branches	insertion_branches	74.50	10 729.00
fallback calls	fallback_calls	0	468.80

Table 4: Métricas internas do solver alemão.

Métrica	Coluna	Mediana	P90
decomposed pieces	decomposed_pieces	50.00	180.40
grouped pieces	grouped_pieces	50.00	180.40
best updates	best_updates	0	1.00
max observed branching	max_observed_branching	5.00	9.00
failed prune count	failed_prune_count	60.00	14 582.80

6 Metodologia e limitações

O solver de ordem livre foi avaliado nas rodadas progressivas de 10, 60, 600 e 3600 segundos; os casos 129 e 541 continuaram em execuções sem limite de tempo com até um bilhão de chamadas. O solver alemão foi avaliado inicialmente nas rodadas progressivas até 1800 segundos. Os casos restantes e todos os casos que tinham sido afetados por limite de branching foram reexecutados por 7200 segundos, com `max_branching=-1` e até 100 milhões de chamadas.

As curvas usam o tempo total registrado em `solver_seconds`. Para evitar uma comparação enganosa com execuções interrompidas, os box plots e o speedup usam somente instâncias certificadas nos dois lados. A curva de instâncias resolvidas preserva os casos exatos e mostra explicitamente a diferença de cobertura entre as abordagens.